# Big Data La numérisation du monde

SI7

Partie 4

- \* Data + réputation :
  - \* Data : données concernant une personne
  - \* Réputation : interprétation des données au sujet d'un individu
- \* Aucun risque de pratiquer les réseaux sociaux
- \* C'est inévitable aujourd'hui, pour exister dans la matrice
- \* Il faut avoir un intérêt à figurer dans ces réseaux (promotion, influence, leader, suiveur, ...)

- \* Bien séparer :
  - \* Vie professionnelle
  - \* Vie privée
  - \* Savoir débrancher quand c'est nécessaire
- \* Privilégier une approche par le haut :
  - Soigner la présentation, éviter le style SMS
  - \* Soigner l'écriture, le story telling
  - \* Prendre le temps d'écriture ou de répondre, relire
  - \* Préciser sa pensée, toujours rester correct

- \* Aucun risque d'être présent sur un réseau social
- \* Ne pas avoir peur d'être fiché (ou alors vivre off-line)
- \* Les réticences vont disparaître (sur les réseaux sociaux) d'autres vont apparaître (robotique)
- \* Etre présent est indispensable pour une frange de la population (jeunes, acteurs du numériques, entreprises)
- \* Il faut avoir quelque chose à dire (sinon ne rien faire)

- \* Pratiquer un réseau à la fois
- \* Chaque réseau à ces spécificités (140 caractères pour twitter, des images pour Pinterest)
- \* Penser à mettre des liens et des images
- \* L'orientation, les couleurs, les sujets sur les images sont importants
- \* Pensez aux canaux différents d'accès:
  - \* Téléphone, tablette, ordinateur (avoir un contenu facilement exploitable)





Positivity breeds engagement and sharing. It will help inspire and excite your users.



The most appealing updates are ones that offer something, but don't disclose everything, making fans want to click on the link.



Results in increased engagement as followers have a visual cue. A good image can tempt followers to RT or share with their followers.



STATUS UPDATE

HTTP://BIT.LY/12ABC45



Make sure to include links to your brands website. Shorten the URL using a bit.ly, which now lets you edit the characters at the end of a link. Making it stand out will increase clickthroughs.



MOBILE FRIENDLY

Remember to use simple imagery that will easily be seen on mobile devices as most of your users will view posts on their phone.



Posts don't just grab attention, comments and responses do. Engage with people and build relationships through conversational dialogue. LIKE · COMMENT · SHARE

COMMENTS



**BE AVAILABLE** 

Post when audience is listening not just when your business is open. This will ensure more engagement from users.



#### CALL TO ACTION

Let your readers know what you would like them to do next.

#### PUNCTUATION

Use capital letters in the correct places and avoid abbreviations.

#### SHORTEN URLS

Bit.ly links generate the most retweets, so shorten all your URLs.

LIUK

### MESSAGE

FORMAT

### MENTIONS

Use questions, facts and figures to engage viewers and drive retweets.

Use mentions to prompt influencers to engage with you and then respond.

#### RETWEET

Retweet relevant content for your audience. Thank people who retweet you.





#### NO HUMAN FACES

Images without faces get repinned more often than images with faces. Images shared by brands, those without human faces are repinned 23 percent more often.



### MULTIPLE

Images with multiple dominant colours garner more than three times the repins.



#### LIGHT AND COLOUR

Images with 50 percent colour saturation got repinned four times as often as images with 100 percent saturation. PIN IT 🔡







#### LITTLE BACKGROUND

When a background rises above 40 percent of the total image area, repins are typically halved or quartered.



### LOTS OF RED

Predominantly red or orange images get twice the repins.



#### PORTRAIT STYLE

Images did best in a vertical orientation with an aspect ration between 2:3 and 4:5.

COMMENTS



USE

Use Hashtags so more

people can find your content. It's a great way to meet people and for other people to find your posts

as well.

HASHTAGS

### GOOGLE+



#### TAG BRANDS AND PEOPLE

Tag Brands and People, when applicable, they'll get a notification and might engage with your post.



HOT

### WHAT'S HOT

STATUS UPDATE

#HASHTAG

Use "What's Hot' to pick a fun and interesting topic, it's also a great way to find people who are currently on G+ to start a conversation with.





#### FULL SIZE IMAGES

Choose a bright, full size photo to run with your post. Do NOT drop a link and use the tiny photo.



Engage with everyone who comments or shares your material. Communication and engagement can't and won't happen if you aren't there.

+1 - SHARE

COMMENTS



## OPTIMUM TIMING FOR SOCIAL POSTS

BEST	WORST
IPM - 4PM	8PM - 8AM
IPM - 3PM	8PM - 9AM
2PM - 4PM	5PM - 7PM
8PM - IAM	
9AM - IIAM	6PM - 8AM
7AM - 9AM	IOPM - 6AM
5PM - 6PM	
	IPM - 4PM IPM - 3PM 2PM - 4PM 8PM - IAM 9AM - IIAM 7AM - 9AM

- \* Comment exploiter les données pour les transformer en réputation
- \* Réputation : ensemble des avis + et relatif à une entité (personne, marque, produit, entreprise)
- \* Name Branding : ou comment transformer votre nom en produit

- \* Accessible à travers plusieurs vecteurs :
  - \* Quantified self (personnal informatics, self tracking)
  - \* Les réseaux sociaux
  - \* Les moteurs de recherche
  - \* Le web sémantique (twitter devient sémantique)
  - \* Les données ouvertes (data.gouv.fr)

- \* Ne pas confondre réputation et notoriété :
  - \* Notoriété: connu ou pas connu (e-notoriété)
  - \* Réputation : évaluation, opinion du public (e-réputation)
- Cela s'amplifie : 4G, 5G, fibre optique, plus de déconnexion, création de flux permanent
- \* Ouverture des API : potentiel de développement
- \* Pouvoir de la CNIL?

- \* L'avenir est dans la data : Google en est le preuve
  - \* Le nier serait se tromper
  - \* Droit à l'effacement
  - \* Droit aux zones blanches
  - Droit à la déconnexion
- \* Avenir:
  - \* web sémantique, intelligence dans la matrice (cloud, fog, iOt)
  - \* Accélération des technologies, des échanges, volumes de données croissants
  - \* Transhumanisme, assistant robotique

- \* Deux types de méthodes :
  - Quantitative : échantillon, set de données complet (statistiques classiques), données forte densité = peu
  - \* Qualitative : à la volée, set de données incomplet (data scientist), données faible densité = beaucoup
- \* Les deux méthodes peuvent se compléter

### \* Objectifs de l'analyse :

- \* De qui parle-t-on? Marque, produit, personne
- \* De quel sujet ? Thématique, actualité, offre
- \* Où parle-t-on? Média, réseau, site, blog, forum
- \* Qui parle ? internaute, blogger, journaliste
- \* Quels jugements ? Avis, recommandations, tonalité

### \* Le Sourcing:

- \* Bouquet disponible : canaux déjà identifiés
- \* Moteur de recherche : afin de trouver des canaux ou des informations
- \* Mieux vaut collecter large que pas assez ...
- \* Ne pas vouloir être exhaustif (impossible avec internet)
- \* Une machine peut être exhaustive avec le temps.
- \* L'échantillon n'est représentatif qu'un court instant (tout évolue en permanence)

- \* Impossible de se passer d'outils informatique : trop de données pour travailler à la main.
- \* Attention au solution entièrement automatique : capacité de discernement, anticipation, disruption, imprévisibilité.
- \* Le traitement des langues et de l'écriture des individus (blog, forum, réseau) nécessite des outils pointus.
- \* Il faut être capable de faire de la sémantique (IA)

- \* Problème de sémantique : AXA
  - \* AXA est une princesse espagnole,
  - une tribu amérindienne,
  - un mouvement politique espagnol,
  - \* un personnage de bande dessinée,
  - \* une expression qui revient dans de nombreuses expressions mathématiques,
  - \* le passé simple du verbe « axer »
  - \* et sûrement d'autres choses encore

### \* Sémantique et tonalité :

- \* Il faut distinguer si le propos est positif ou négatif
- \* « ce somnifère calme mes angoisses » : positif
- \* « depuis que je prends ce médicament mes angoisses ont disparu » : positif
- \* « ce somnifère ne calme plus mes angoisses » : négatif

- \* Repérer les influenceurs (likes Facebook)
- \* Repérer les suiveurs (followers Twitter)
- \* Popularité : nombre d'amis, de fans, de contacts
- \* Indice: tout est quantifiable avec le Big Data
- Attention : tout peut bouger dans le temps
- \* Importance dans le B to C
- \* Mais également dans B to B
- \* Transposable au M to M

### \* Objectifs:

- \* Décrire une population (pas par ses attributs)
- \* Par la relation entre ses membres
- Par la façon d'intéragir
- \* Par la façon de se comporter

- \* Netnographie : analyse qui renvoie aux groupes, aux individus présent sur un réseau numérique
- \* Ethnographie : science de l'anthropologie, qui passe par une étude descriptive et analytique
- \* Anthropologie : étude de l'être humain sous tous ces aspects.
- \* Les réseaux sociaux numériques facilitent les études qui seraient impossibles dans le réel.
- \* Réseaux sociaux : sociétés numérisées !

- \* L'analyse des réseaux sociaux utilise :
  - \* Sociométrie : mesure de l'état économique et social des peuples
  - \* L'anthropologie
  - \* Les mathématiques : théorie des graphes, algèbre linéaire, statistiques

### \* Sociométrie:

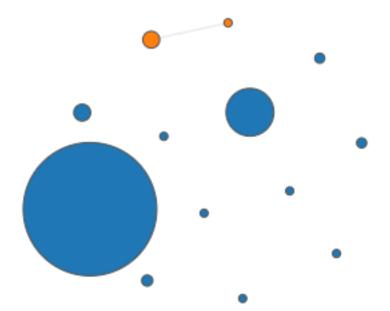
- \* Vise à établir des catégories d'individus en fonction de leur aptitude à s'imposer comme meneur
- \* Le meneur influent, et lui-même désigné par des individus à statut sociométrique élevé (le meilleur choix)
- \* Le meneur populaire sera choisi par des individus isolés, peu choisis, avec un statut moins élevé (le choix par défaut)
- \* L'empathie peut être à l'origine du leadership.

### \* Sociométrie:

- \* Individus centraux : assure la cohésion d'un groupe
- \* Individus ponts : relie des groupes entre eux
- \* Ces individus doivent faire partie de l'étude pour être fiable
- Cela suppose donc une mise en place de l'échantillon raisonnée, pour cerner les bonnes personnes
- \* Ce que ne propose pas toujours le Big Data (échantillon brut)

- \* Outils d'analyse des réseaux sociaux :
  - \* Automap: <a href="http://www.casos.cs.cmu.edu/projects/automap/">http://www.casos.cs.cmu.edu/projects/automap/</a>
  - \* Cfinder: <a href="http://www.cfinder.org">http://www.cfinder.org</a>
  - \* Commetrix: <a href="http://www.commetrix.de">http://www.commetrix.de</a>
  - \* Dynet: <a href="http://www.casos.cs.cmu.edu/projects/DyNet/">http://www.casos.cs.cmu.edu/projects/DyNet/</a>
  - \* Egonet: <a href="http://sourceforge.net/projects/egonet/">http://sourceforge.net/projects/egonet/</a>
  - \* Idiro: <a href="http://www.idiro.com">http://www.idiro.com</a>
  - \* KXEN: <a href="http://www.kxen.com/Products/Social+Network+Analysis">http://www.kxen.com/Products/Social+Network+Analysis</a>

- \* Outils d'analyse:
  - \* Immersion MIT : yahoo, gmail, Msexchange : <a href="https://">https://<a> immersion.media.mit.edu



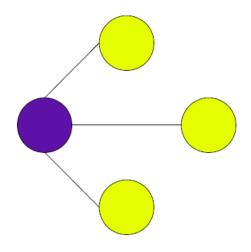
### \* Outils d'analyse :

- \* netvis: <a href="http://www.netvis.org">http://www.netvis.org</a>
- \* R: <a href="http://www.r-project.org">http://www.r-project.org</a>
- \* Java Universal network : <a href="http://jung.sourceforge.net">http://jung.sourceforge.net</a>

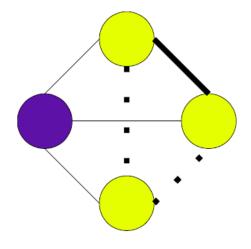
### \* Homophilie:

- \* Recherche d'individus semblable à soi à plusieurs niveaux (centre d'intérêt, pratique, métier, ...)
- \* A travers la distance géodésique : chemin le plus court (effet petit monde)
- \* A travers sont coefficient de clustering : probabilité que deux voisins d'un nœud, soit voisin entre eux (triangulation)
- \* Coefficient clustering = coefficient d'agglomération = tendance à la grégarité!

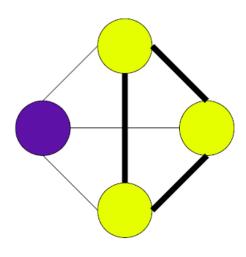
### \* Coefficient de clustering :



(a) No pairs formed among neighbors:  $C = \theta$ 



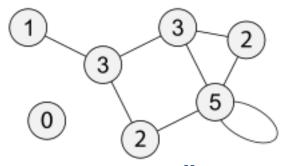
(b) One pair formed among neighbors: C = 1/3



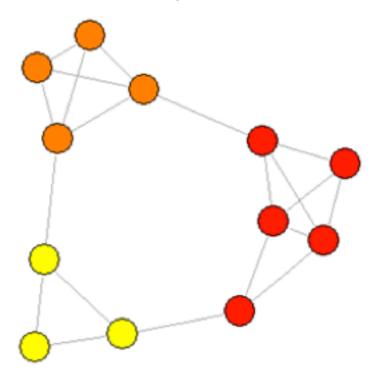
(c) Three pairs formed among neighbors: C = 3/3

- \* Configuration des principaux graphes :
  - \* Faible distance géodésique :
  - \* Fort coefficient de clustering
  - \* Distribution particulière des « degrees » : (nombre d'individus connectés à un individus donnés)
- \* Pour les deux premiers paramètres : effet petit monde
- \* Degree:
  - \* Grande majorité de sommets à faible « degree »
  - \* Nombre faible de sommets à très haut « degree » = Hub

- \* Degrés (Degrees):
  - \* Le degré correspond au nombre lien sur chaque sommet.
  - \* Dans un graphe orienté on peut noter ce nombre sur les sommets.



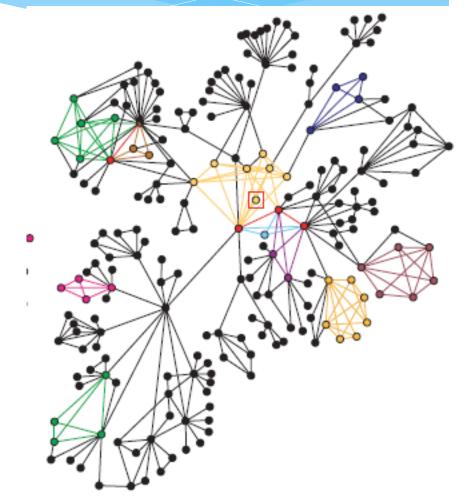
- \* Structure en communauté (graphes réels):
  - \* Inhomogénéité traduisant une organisation complexe
  - Les hubs sont structurants
  - \* Les hubs sont médiateurs



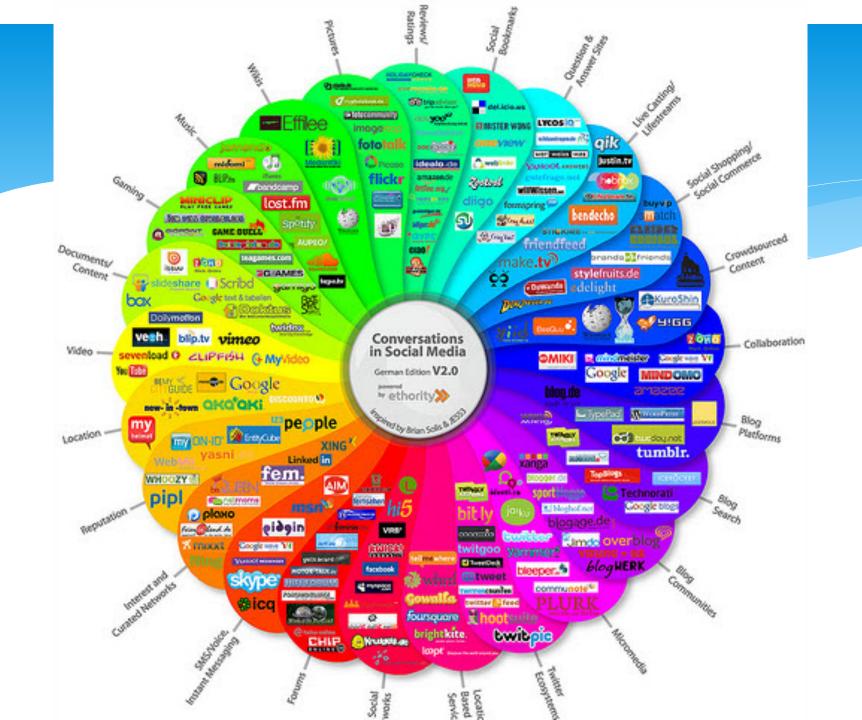
### \* Degré de relation :

- \* Le degré de relation peut varier en 4 et 6 personnes
- \* Entre deux personnes prises de manière aléatoire
- \* Le monde est petit!
- \* Ce sont les leaders qui rendent le monde petit
- \* Ils resserrent les réseaux à leur niveau (majorité des contacts passent par eux)
- \* Les Hubs fabriquent un réseau robuste.

\* Modélisation:



- \* 4 types de communauté en ligne :
  - \* les communautés de transaction,
  - \* les communautés de relations,
  - \* les communautés de fantaisie
  - \* et les communautés d'intérêt.





#### \* Liens:

- Liens faibles : personnes avec lesquelles nous n'avons aucun lien d'amitié, de parenté direct au départ
- \* Un parent, une épouse, un frère, sont des liens forts
- \* Liens forts : à force de pratiquer, et de se confier, les liens faibles, deviennent plus forts, que les liens forts !

- \* Comparaison virtuel / réel :
  - \* les liens sont plus faibles en moyenne qu'au sein des communautés traditionnelles
  - \* ils sont plus éphémères voire plus disjoints
  - \* les réseaux sont plus segmentés et à densité plus faible
  - \* le nombre de liens donc la taille des réseaux semble plus faible
  - \* Un petit nombre d'individus maintient le réseau
  - \* Le noyau est très dense est constant
  - \* Le caractère fluctuant se situe aux extrémités
  - \* Des similitudes existent cependant entre les deux mondes

# 3. Analyse des réseaux

#### \* Viralité:

- \* Caractéristique des réseaux avec des sommets à faibles degrees.
- \* absence de sommet à très haut degrees (centralisateur/bloquant)

#### \* Chevauchement:

- \* Appartenance à plusieurs réseaux sociaux (ponts)
- \* Intermédiarité nécessaire pour des apports, échanges

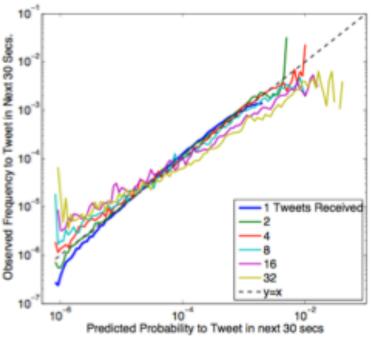
# 3. Analyse des réseaux

#### \* Viralité:

\* Une étude démontre :

Que la contagion peut se faire jusqu'à un certain niveau : à cause de l'exposition au message

\* Ensuite, à cause de la limite du cerveau, la propagation se réduit.



#### \* Viralité:

- \* Le marketing virale est une arme
- \* Il utilise les principe de transmission d'une maladie

### \* Leadership:

- \* N'est pas une position figée (sauf à partir d'un certain niveau de sociométrie)
- \* Le leader, peut générer un bruit de fond
- \* Les liens faibles dans ce cas sont nombreux (pas assez d'autres leaders pour noyer le bruit)

- \* Réseau égocentré (jeux vidéos) différences de sociabilité :
  - \* Spécialisation : cercle de sociabilité => différents groupes
  - Distribution : pratique culturelle qui peut se transmettre à deux groupes => échange
  - \* Polarisation : pratique culturelle qui ne s'échange pas (clan, noyau fusionnel)

#### \* Sociabilité:

- \* hyperspécialisée : un seul réseau (Zynga)
- \* Polarisée : évangélisateur, clan (Apple, Microsoft)
- \* Distribuée : plusieurs réseau réels ou virtuels

- \* Angle d'approche (étude):
  - \* Pouvoir distinguer au sein des communautés des zones de production
  - \* Surveiller certaines zones (singles, régions moyennes)
  - \* Distinguer le ou les noyaux durs de la communauté
  - \* Identifier les ponts au sein de la communauté
  - \* Repérer les acteurs et déceler les nouveaux leaders
  - \* Visualiser la confiance et les liens réciproques
  - \* Prendre en compte le capital social des leaders, identifier leur position au sein du réseau
  - Pouvoir étudier une communauté en ligne en liaison avec d'autres types de réseau

- \* Gestion de la réputation :
- Groupes de boycott (groupes hostiles)
- \* Groupes de fans
- \* Guerre de position :
  - \* Maîtrise des groupes ponts
  - Isolement des groupes hostiles
  - \* Suivi de la forme du réseau
  - \* Déplacement du noyau (politique)
  - Quantification des échanges

### \* Techniques nécessaires :

- \* Importance de la sémantique (nouvel enjeux ?)
- \* Mise en place d'ontologies
- \* Recherche des occurrences : cooccurrences (association entre noms et termes)
- \* Marques/qualificatifs, Marques/qualificatifs/noms

\* Top 10 des réseaux sociaux préférés : (chiffres 2014)

Rang	Site internet	Votes (en %)
1	Facebook	66,9%
2	Youtube	10,1%
3	Twitter	4,3%
4	Skype	3,0%
5	Google+	2,2%
6	LinkedIn	1,4%
7	Copains d'avant	1,0%
7	Instagram	1,0%
9	Viadeo	0,9%
10	Windows Live	0,8%

Base: 18 176 visiteurs réguliers de réseaux sociaux

### \* Top 10 petites annonces/ventes entre particuliers

Rang	Site internet	Votes (en %)
1	leboncoin.fr	72,9%
2	ebay.fr	6,6%
3	amazon.fr	3,8%
4	priceminister.com	3,2%
5	paruvendu.fr	2,0%
6	vivastreet.fr	1,5%
7	pap.fr	1,3%
8	fnac.com	0,9%
9	entreparticuliers.com	0,8%
10	lacentrale.fr	0,7%

Base : 18 162 visiteurs réguliers de sites de petites annonces/vente entre particuliers

\* Top 10 sites dédiés à la maison (bricolage, déco, jardins)

Rang	Site internet	Votes (en %)
1	leroymerlin.fr	14,6%
2	ikea.com	12,7%
3	castorama.fr	6,5%
4	conforama.fr	4,4%
5	maisonsdumonde.com	3,9%
5	bricodepot.fr	3,9%
7	deco.fr	3,4%
8	aufeminin.com (rubrique déco)	3,1%
9	alinea.fr	2,7%
10	marieclairemaison.com	2,5%

Base : 13 785 visiteurs réguliers de sites de maison (décoration, bricologe, jardinage)

### \* Top 10 sites de vidéos:

Rang	Site internet	Votes (en %)
1	youtube.com	69,2%
2	allocine.fr	3,3%
2	dailymotion.com	3,3%
4	6play.fr	2,0%
4	tf1.fr	2,0%
6	arte.tv	1,9%
6	facebook.com	1,9%
8	pluzz.fr	1,7%
9	tv-replay.fr	1,6%
10	iTunes	1,1%

Base : 18 116 visiteurs réguliers de sites de partage de vidéos

### \* Top 10 sites d'actualités :

Site internet	Votes (en %)
lemonde.fr	10,5%
20minutes.fr	8,6%
google actualités	7,4%
yahoo! actualités	4,8%
lefigaro.fr	4,5%
bfmtv.com	4,4%
orange actualités	3,9%
msn actualités	3,6%
leparisien.fr	3,6%
ouest-france.fr	2,9%
	lemonde.fr 20minutes.fr google actualités yahoo! actualités lefigaro.fr bfmtv.com orange actualités msn actualités

Base: 18 080 visiteurs réguliers de sites d'actualités, informations généralistes

#### \* Top 10 sites d'actualités sportives :

Rang	Site internet	Votes (en %)
1	lequipe.fr	27,5%
2	eurosport.fr	10,8%
3	orange sport	3,7%
4	rugbyrama.fr	2,5%
5	canalplus.fr (rubrique sport+)	2,4%
5	yahoo! sport	2,4%
7	sport24.com	2,1%
8	beinsport.fr	1,9%
9	actu-foot.fr	1,7%
10	francefootball.fr	1,6%

Base: 8 691 visiteurs réguliers de sites de sport

\* Top 10 sites catégorie famille (parents, santé, ...)

Rang	Site internet	Votes (en %)
1	doctissimo.fr	25,4%
2	aufeminin.com (rubrique maman)	9,6%
3	parents.fr	5,2%
4	allodocteurs.fr	5,1%
5	magicmaman.com	3,7%
6	e-sante.fr	3,2%
7	santepratique.fr	3,1%
8	familles.com	3,0%
9	femmeactuelle.fr (rubrique enfant)	2,8%
9	psychologies.com (rubrique familles)	2,8%

Base : 8 148 visiteurs réguliers de sites pour les familles

### \* Top 10 sites catégorie jeux vidéos :

Rang	Site internet	Votes (en %)
1	jeuxvideo.com	40,4%
2	jeuxvideo.fr	7,8%
3	gamekult.com	4,3%
4	micromania.fr	3,7%
5	steam	3,6%
6	canardpc.com	2,6%
7	millenium.org	2,1%
7	xbox.com	2,1%
9	playstation.com	1,7%
10	jeuxonline.info	1,5%

Base : 7 216 visiteurs réguliers de sites de jeux vidéo

### \* Top 10 sites catégorie Auto/moto

Rang	Site internet	Votes (en %)
1	leboncoin.fr	13,1%
2	turbo.fr	7,8%
3	lacentrale.fr	7,4%
4	autoplus.fr	7,0%
5	oscaro.com	6,0%
6	automoto (tf1.fr/auto-moto)	5,0%
7	caradisiac.com	4,6%
8	moto-journal.fr	2,7%
9	autojournal.fr	2,5%
10	moto-station.com	1,6%
10	renault.fr	1,6%

Base : 5 701 visiteurs réguliers de sites auto-moto

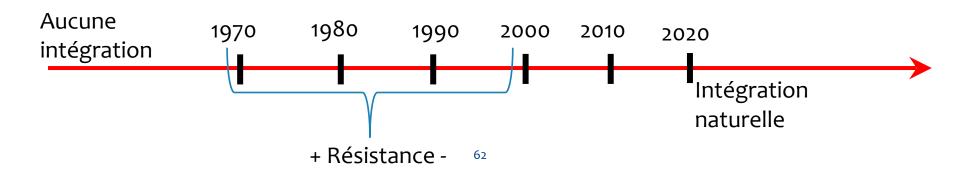
# 4. La Data ne peut pas tout?

- \* Big Data : prédiction / intelligence
- \* Humain: disruption possible/anticipation
- \* Machine : base de connaissances, problème d'anticipation
- \* Limite des statistiques : set de données limitées
- \* Big Analytics : set de données colossale (problème de data driven, complexité des algorithmes)

## 4. La Data ne peut pas tout?

- \* Lien corrélation/causalité
- \* Problème de prédiction en utilisant des données du passé ? (répétition de l'histoire, conditions similaires)
- \* Problème de l'epsilon dans l'équation de prédiction (problème d'incertitude)
- \* Le problème réside dans l'intelligence des systèmes (avenir proche ou lointain)

- \* Nous vivons dans une période qui va bouleverser nos vies et changer nos habitudes.
- \* Cependant, ce n'est pas la première fois, ni la dernière.
- \* Peut être avons nous un problème d'adaptation rapide ?



- \* Avenir de la France en matière de Big Data :
  - \* Ministre de l'économie Numérique (Fleur Pèlerin Filière Big Data)
  - \* Ministre du redressement Productif (Arnaud Montebourg Daily Motion
  - \* Rapport commission innovation 2030 (Anne Lauvergeon)
  - \* Dynamique internet Prospective 2030 (Commissariat Général à la stratégie et prospective)
- \* Aucun lien entre les annonces
- \* Pas de filière du numérique en France au niveau des acteurs de l'éducation
- \* Beaucoup d'annonces! Peu d'effets!

- \* Nous avons raté plusieurs virage du numérique :
  - \* Le smartphone, les tablettes
  - \* Ne pas rater celui du M to M (internet des objets, robotique)
- \* Problème de passage R&D au Business Model (lenteur des expérimentations, financement, contraintes fortes)
- \* Protection des individus, de la vie privée : CNIL
- \* Plus grande complexité, propriété intellectuelle.

- \* Tradition centralisée, état décideur, Colbertisme, actions régaliennes.
- \* Pression fiscale pour les créateurs d'entreprises (petites structures)
- \* Culture du numérique?
- \* Conjoncture morose (cela peut durer longtemps ...)
- \* Quelques atouts : Critéo, Withings, Parrot, Alsthom Grid, ...

## Merci

\* Avez-vous des questions?